

素粒子実験学ゼミナール B レポート課題

学籍番号 0530371470 田中 智也

2026 年 2 月 27 日

序論

本課題は、30 個の変数から Signal ($h \rightarrow \tau\tau$) と Background を分離するという 2 値分類の問題となっている。入力変数は 13 個の DER から始まる high level 変数と、それらを作るのに必要な 17 個の low level 変数とに別れているものの、基本的には順序なしの 1 次元入力となっている。このような入力変数の場合、基本的には BDT や LightGBM といった決定木ベースのブースティング手法が一般に手堅い手段であるが、ここではあくまで Neural Network (NN) を利用したモデルにこだわった。

モデル

使用したモデルは ResNet をベースとしている。ResNet 構造を用いることで、より階層の深いモデルでも学習が可能となる。また、本モデルでは複数の ResNet に対してさらに残差接続を設けることで、より多くの層をまんべんなく学習できるよう工夫している。

損失関数には、2 値分類に強い BCELoss を使用し、optimizer には AdamW を使用している。また、現代の機械学習に多く取り入れられている以下のベーシックな手法も採用している。

- データセットの normalization
- Learning rate (lr) の scheduler (はじめは低い lr から数エポックで最大に達し、後は各エポックごとに 0.95 倍で減衰するようにした)
- Dropout, weight decay
- Early stopping、及び validation loss が最小のところでモデルを保存する機能

Validation dataset の結果

training.csv のうち 80% を training dataset とし、残りの 20% を validation dataset とした。Validation dataset の AMS は、1.5925 であった。元の dataset のサイズに scale すると、およそ 3.56 となる。一方、LightGBM を使用した場合は AMS は 1.5908 であり、NN モデルがわずかに上回る結果となった。しかし、学習によってこの値はバラつきうるため、学習の容易さも加味するとやはり LightGBM が最適な選択であると考えられる。